



SAĞLIKTA YAPAY ZEKA PROJESİ 2025

NeuroCode AI takımı



İNÖNÜ
UNİVERSİTESİ

TEKNOLOJİ
FESTİVALI



Biz Kimiz?

Biz, yapay zekaya, görüntü işlemeye ve sağlık teknolojilerine tutkuyla bağlı bir ekip olarak NeuroCode AI projesini hayata geçirdik. Amacımız, beyin BT görüntüleri üzerinden inme tespiti yapabilen, hayat kurtarıcı ve erişilebilir bir sistem geliştirmektir.

Bu süreçte sadece yazılım ve model geliştirmedik, aynı zamanda ekip ruhuyla birlikte başarmanın gücünü hissettik. Her birimiz farklı alanlarda katkı sağladık; bazen kod satırlarında boğulduk, bazen bir kahve molasında çözümü bulduk ama her zaman inançla ilerledik.

Adı Soyadı	Bölüm/Üniversite	Görevi
Ahmed İkbāl Bekmezci	Bilgisayar Mühendisliği / İnönü Üni.	Ekip Kaptanı
Sercan Şen	Bilgisayar Mühendisliği / İnönü Üni.	Ekip Üyesi
Ömer Memiş	Bilgisayar Mühendisliği / İnönü Üni.	Ekip Üyesi
Hacı Yeşil	Bilgisayar Mühendisliği / İnönü Üni.	Ekip Üyesi
Fırat Kılıç	Bilgisayar Mühendisliği / İnönü Üni.	Ekip Üyesi

1. İnme Nedir?

İnme, beyin damarlarında meydana gelen ani bir bozulma sonucu, beynin bir bölümüne giden kan akışının kesilmesiyle ortaya çıkan ciddi bir sağlık sorunudur. Bu durum, beyin hücrelerinin oksijen ve besin alamamasıyla birlikte dakikalar içinde hasar görmesine yol açar.

İnme Türleri:

- **İskemik İnme:** %85 oranında görülür. Beyne giden damarların tıkanması sonucu oluşur.
- **Hemorajik (Kanayıcı) İnme:** Beyin damarının yırtılarak kanamasıyla meydana gelir.
- **Geçici İskemik Atak (Mini İnme):** Kısa süreli damar tıkanıklığı yaşanır, geçicidir fakat uyarı niteliğindedir.

Belirtiler:

- Yüzde, kolda veya bacakta ani uyuşma veya güçsüzlük (özellikle vücudun bir tarafında)
- Konuşma bozukluğu veya anlamada zorluk
- Görme problemleri
- Denge kaybı, baş dönmesi
- Ani ve şiddetli baş ağrısı

Toplumsal Etki:

- İnme, dünya genelinde en sık görülen ölüm nedenlerinden biridir.
- Hayatta kalan bireylerin büyük bir kısmı kalıcı fiziksel ya da zihinsel engellerle yaşamını sürdürmek zorunda kalır.
- Erken teşhis ve müdahale, hem yaşam kurtarıcı hem de iyileşme şansını artırıcı bir etkidir.

! İnmenin dakikalar içinde beyinde kalıcı hasar bırakabileceği unutulmamalıdır. Bu nedenle hızlı tanı ve doğru müdahale, hayat kurtarır.

2. Projenin Amacı ve Katkısı

Merhaba arkadaşlar! NeuroCode AI projemizin amacı ve sağladığı katkılardan biraz bahsetmek istiyorum.

Neden Bu Projeyi Geliştirdik?

İnme teşhisinde en önemli şey zamandır! "Zaman = Beyin" deyişi tam da bunu anlatır. Her geçen dakika, beyin hücreleri geri dönüşümsüz hasar görür. Maalesef radyologların BT görüntülerini değerlendirmesi zaman alabiliyor, özellikle gece saatlerinde veya küçük hastanelerde uzman bulunmadığında.

İşte biz de dedik ki: "Ya yapay zeka, radyologlara yardımcı olabilse ve inme tespitini hızlandırabilse?"

Projemizin Ana Hedefleri:

- İnme vakalarını %98 gibi yüksek doğrulukla tespit etmek
- Teşhis süresini dakikalardan saniyelere indirmek
- Özellikle uzman hekimin olmadığı durumlarda sağlık personeline destek olmak
- İnme tedavisinde "altın saati" daha iyi değerlendirmek

Topluma Katkısı Nedir?

Her yıl milyonlarca insan inme geçiriyor ve maalesef birçoğu ya hayatını kaybediyor ya da kalıcı sakatlıkla yaşamak zorunda kalıyor. Modelimiz:

- Daha hızlı teşhisle hayat kurtarabilir
- Kalıcı beyin hasarı riskini azaltabilir
- Tedavi maliyetlerini düşürebilir
- Sağlık sistemindeki yükü hafifletebilir

Yenilikçi Yanı Nedir?

Modelimiz sadece "inmeli/inmesiz" demiyor! EfficientNetB0 mimarisiyle yaptığımız çalışmalar, benzer sistemlerden daha yüksek doğruluk sunuyor. Üstelik sıradan bir bilgisayarda bile çalışabiliyor.



3. Kullanılan Veri Seti

Merhaba arkadaşlar! Projemizde kullandığımız veri setinden bahsetmek istiyorum.

Veri Setimizin Kaynağı 📁

TEKNOFEST tarafından bize sağlanan, toplamda 6947 beyin BT görüntüsünden oluşan kapsamlı bir veri setiyle çalıştık. Bu görüntüler:

- 2383 inme olan hasta görüntüsü
- 4564 inme olmayan hasta görüntüsü içeriyordu.

Veri Setinin Özellikleri 🔍

Veri setimiz gerçek hastalardan alınan anonim BT taramaları içeriyordu. Bu görüntüler:

- Farklı hastanelerden
- Farklı BT cihazlarından
- Çeşitli yaş ve cinsiyet gruplarından gelen bir çeşitlilik sunuyordu.

Karşılaştığımız Zorluklar ve Çözümlerimiz 💡

Veri setiyle çalışırken birkaç zorlukla karşılaştık:

1. **Dengesiz Veri:** İnme olmayan görüntüler, inme olanların neredeyse iki katıydı. Bunu çözmek için veri artırma teknikleri kullandık - yani mevcut inme görüntülerini döndürme, aynalama ve kontrast değişiklikleri ile çoğalttık.
2. **Görüntü Kalitesi:** Bazı görüntüler diğerlerinden daha az netti. Standardizasyon için hepsini aynı boyuta getirdik ve ön işleme teknikleriyle kalitelerini dengeledik.
3. **Etiketleme:** Tüm görüntüler profesyonel radyologlar tarafından "inmeli" veya "inmesiz" olarak etiketlenmişti, bu da güvenilir bir temel oluşturdu.

Verilerin Bölünmesi 🧩

Modelimizi eğitmek ve test etmek için veri setimizi şöyle böldük:

- %70 Eğitim için (modelin öğrenmesi)
- %15 Doğrulama için (eğitim sırasında ayarlamalar)
- %15 Test için (final performans değerlendirmesi)

Bu sayede modelimizin daha önce hiç görmediği görüntüler üzerindeki gerçek performansını ölçebildik.



4. Yöntem ve Modelleme

Merhaba arkadaşlar! Şimdi sizlerle projemizin en heyecan verici kısmını, yani nasıl bir yapay zeka modeli oluşturduğumuzu paylaşacağım.

Modelimizi Nasıl Geliştirdik? 🛠️

Beyin BT görüntülerinden inme tespiti yapmak için şu adımları izledik:

1. Veri Ön İşleme

- Tüm görüntüleri 224x224 piksel boyutuna getirdik
- Görüntülerdeki gürültüyü azalttık
- Kontrastı iyileştirdik
- Beyin bölgesine odaklanmak için gereksiz kısımları kırdık

2. Model Seçimi ve Karşılaştırma 🔍 Birçok farklı derin öğrenme modelini test ettik:

- EfficientNetB0
- DenseNet121
- SEResNet50
- EfficientNetB3
- ResNet50

En yüksek başarıyı **EfficientNetB0** modeli ile elde ettik (%98.10 doğruluk).

3. Transfer Öğrenme Yaklaşımı 🔄 Sıfırdan bir model eğitmek yerine, ImageNet veri seti üzerinde önceden eğitilmiş EfficientNetB0 modelini kullandık ve kendi veri setimize uyarladık. Bu sayede:

- Eğitim süresini kısalttık
- Daha az veri ile daha iyi sonuçlar aldık
- Modelin genelleme yeteneğini artırdık


4. Model Optimizasyonu ⚙️ Modelimizi en iyi performansa ulaştırmak için:

- Öğrenme oranını 0.0001 olarak belirledik
- Aşırı öğrenmeyi önlemek için dropout (0.25) kullandık
- Batch size değerini 8 olarak ayarladık
- 50 epoch eğitim sürdürdük ama "early stopping" ile gereksiz eğitimi önledik




5. Sonular


Tüm Modellerin ROC Eğrileri



Yakınlaştırmış ROC Eğrileri



Modellerin AUC Değerleri



Optimal Noktalar ve Eşik Değerleri

Model	FPR	TPR	Eşik Değeri
EfficientNetB0	0.0191	0.9790	0.4033
DenseNet121	0.0131	0.9748	0.4704
SEResNet50	0.0164	0.9727	0.4286
EfficientNetB3	0.0125	0.9757	0.4629
ResNet50	0.0125	0.9656	0.4743



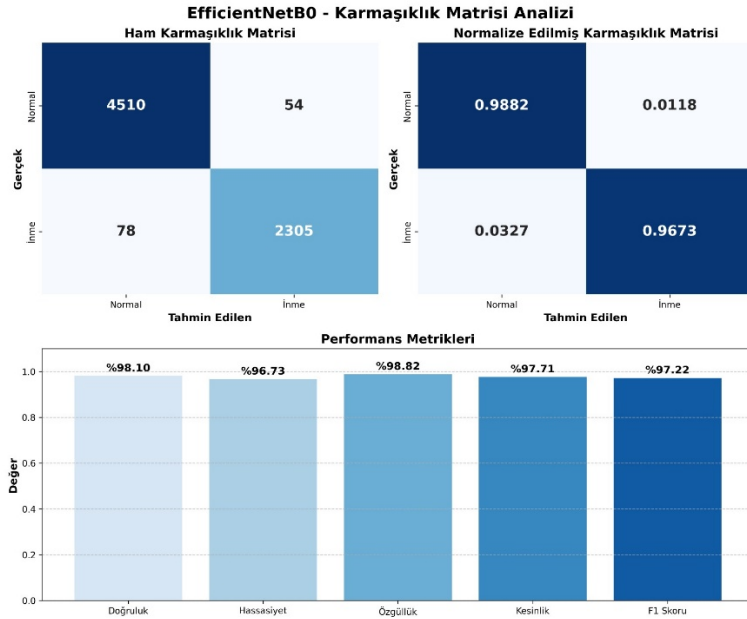
ROC Eğrileri Analizi

Üstteki grafikte gördüğünüz ROC eğrileri, her modelin farklı eşik değerlerinde doğru pozitif oranı (TPR) ve yanlış pozitif oranı (FPR) arasındaki ilişkiyi gösteriyor. Hepsi birbirine yakın performans gösterse de, detaylara baktığımızda:

- EfficientNetB0 modelimiz 0.9962 AUC değeriyle en iyi performansı gösterdi
- EfficientNetB3 de 0.9967 ile çok yakın bir sonuç elde etti
- Diğer modeller de 0.99'un üzerinde değerlerle oldukça başarılı

🧠 Neden EfficientNetB0'ı Seçtik?

1. Düşük Yanlış Pozitif Oranı: Tablodan görüldüğü gibi, EfficientNetB0 sadece 0.0191 FPR (yanlış pozitif oranı) ile çalışıyor. Yani "inmesiz" hastaları "inmeli" olarak yanlış etiketleme oranı çok düşük!
2. Yüksek Doğruluk: %98.10 genel doğruluk oranıyla en iyi değeri sunuyor. Bu da yaklaşık her 100 hastadan sadece 2'sinde hata yapabileceği anlamına geliyor.



📊 Karmaşıklık Matrisi Ne Anlatıyor?

Alt kısımdaki karmaşıklık matrisi, EfficientNetB0 modelimizin performansını daha detaylı gösteriyor:

- 4510 doğru negatif: inmesi olmayan hastaları doğru tespit etmiş
- 2305 doğru pozitif: inmeli hastaları doğru tespit etmiş
- Sadece 54 yanlış pozitif: inmesi olmayan 54 hastayı yanlışlıkla inmeli olarak işaretlemiş
- 78 yanlış negatif: inmeli 78 hastayı gözden kaçırmış

Bu sonuçlara göre modelimiz:

- %98.82 özgüllük (inmesiz hastaları doğru tespit etme)
- %96.73 hassasiyet (inmeli hastaları doğru tespit etme)
- %97.71 kesinlik (inmeli dediği hastaların gerçekten inmeli olma oranı)

6.Başarımızın Sırrı Neydi?

Modelimizin bu kadar başarılı olmasındaki en önemli faktörler:

- **Veri Artırma Teknikleri:** İnme görüntülerini döndürme, çevirme, yakınlaştırma gibi tekniklerle çoğalttık
- **Dengeli Eğitim:** Veri setindeki dengesizliği gidermek için özel yöntemler kullandık
- **Doğru Mimari Seçimi:** EfficientNetB0, az parametre ile yüksek başarı sundu
- **Hiperparametre Optimizasyonu:** En iyi performansı veren ayarları bulmak için sistematik deneyler yaptık

Teknik Detaylar (Merak Edenler İçin)

- Programlama Dili: Python
- Kütüphaneler: TensorFlow, Keras, NumPy, OpenCV
- GPU: Google Colab Pro üzerinde eğitim gerçekleştirdik
- Eğitim Süresi: Yaklaşık 4 saat

Modelimiz, %98.10 doğruluk oranı ile bir radyoloğun bile gözünden kaçabilecek inme belirtilerini tespit edebiliyor. Özellikle küçük ve erken dönem inmeleri yakalamadaki başarısı, erken müdahale şansını artırarak hayat kurtarma potansiyeline sahip.

En basit haliyle söylemek gerekirse: Bilgisayar, binlerce beyin görüntüsüne bakarak "inmeli beyin nasıl görünür" sorusunun cevabını öğrendi ve şimdi yeni gördüğü beyinlerde inme olup olmadığını söyleyebiliyor!